

试题一

一、计算题（每题 10 分，共 20 分）

$$[(n-3)+1] \times [(m-3)+1]$$
$$= (n-2) \times (m-2)$$

- 1、一个 $n \times m$ 的图像经过 3×3 的卷积核卷积后的尺寸是多少？（步长为 1）
- 2、某 MLP 模型，输入层有 4 个神经元，第 1 隐藏层的某个神经元 N_k 与输入层连接的权重分别为 0.3、0.5、0.4、0.2，当输入为 1、0、1、1 时，求神经元 N_k 的值（激活函数为 ReLU）。
 $z = 0.3 \times 1 + 0.5 \times 0 + 0.4 \times 1 + 0.2 \times 1 = 1.2$

$$z = 0.3 \times 1 + 0.5 \times 0 + 0.4 \times 1 + 0.2 \times 1 = 0.9$$
$$\text{ReLU}(z) = \max(0, z) = \max(0, 0.9) = 0.9$$
$$V_k = 0.9$$

二、简答题（每题 10 分，共 60 分）

- 1、请叙述卷积神经网络的优点。
- 2、写出 SiLU 激活函数的表达式，并叙述 SiLU 的优点。
- 3、Softmax 的作用是什么？
- 4、强化学习在 ChatGPT 的训练中起什么作用？
- 5、在利用 CNN 实现人脸识别中，什么是特征向量？
- 6、在 Mamba 模型中 HiPPO 起到了什么作用？

上不同的类外数据的概率分布各有差异。或者说,每一类外数据都有唯一的概率分布,这种概率分布称为该数据的特征变量。

三、综合题（每题 5 分，共 20 分）

用孪生 CNN 网络设计学校刷脸门禁系统。请


- 1、画出孪生 CNN 网络结构。
- 2、请描述正、负样本的构成

2. 正样本: 同一人的两张不同人脸图像, 标签为 1.
负样本: 不同人的两张人脸图像, 标签为 0.

- ### 3、回答：什么是余弦相似度？

$$3. \text{ similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{A \cdot A} \sqrt{B \cdot B}}$$

- #### 4、孪生 CNN 训练的结果是否适用于图像检索，为什么？

$$\frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$


4 适用

1. 孪生CNN训练的核心目标是学习到具有区分性的特征表示，让同类样本的特征在向量空间中距离近、不同类样本距离远。
2. 图像检索的本质是：对输入的查询图像，在数据库中找到特征空间中最相似的图像。
3. 孪生CNN提取的特征向量可以直接作为图像的“特征指纹”，通过计算查询图像特征与数据库中所有图像特征的余弦相似度/欧氏距离，就能返回最相似的图像结果。

1、卷积神经网络的优点

- 局部感知：卷积层通过卷积核只感受局部区域的信息，能捕捉图像的边缘、纹理等基础特征。
- 权值共享：同一个卷积核在整张图像上共享参数，大幅减少参数量，降低计算复杂度，同时提升模型泛化能力。
- 池化降维：池化层可以降低特征图的空间尺寸，减少计算量，同时保留关键特征，让模型对微小的位置变化更鲁棒。
- 层级特征提取：浅层提取低级特征（边缘、纹理），深层提取高级特征（部件、目标整体），适配图像的层次化信息结构。

2. 表达式

$$\text{SiLU}(x) = x \cdot \sigma(x) = x \cdot \frac{1}{1 + e^{-x}}$$

优点：

1. 无上界有下界：避免了ReLU的神经元死亡问题，同时不会出现梯度爆炸。
2. 平滑性好：处处可导且导数连续，比ReLU更易优化，训练过程更稳定。
3. 单侧抑制：对负输入有一定的抑制作用，同时保留了部分负信息，比Sigmoid、Tanh更适合深层网络。

4. ChatGPT训练中使用的是RLHF（基于人类反馈的强化学习），作用如下：

1. 对齐人类偏好：通过人类标注员对模型输出打分，让模型学习生成更符合人类习惯、有用、无害的回答。
2. 优化生成质量：用强化学习的奖励信号指导模型调整策略，解决预训练模型可能出现的生硬、跑题、有害内容等问题。
3. 提升交互体验：让模型的回答更具连贯性、逻辑性和实用性，更贴近真实对话场景的需求。

6. HiPPO（High-order Polynomial Projection Operator）是Mamba模型的核心理论基础之一，作用如下：

1. 建模长序列依赖：HiPPO可以将序列的历史信息投影到固定维度的状态空间中，让模型高效捕捉长距离的依赖关系。
2. 提升计算效率：它为Mamba的选择性状态空间（SSM）提供了理论支撑，使模型能在 $O(n)$ 复杂度下处理长序列，解决Transformer中注意力机制的 $O(n^2)$ 复杂度瓶颈。
3. 增强序列建模能力：HiPPO的设计让模型能动态保留和更新序列信息，对长文本、长语音等场景的建模效果更优。

一、简答（每题15分，共60分）

1、请叙述多层感知机（MLP）的优点和缺点。

优点

1. 结构简单易实现：由全连接层堆叠而成，逻辑清晰，易于理解和搭建。
2. 通用逼近能力：理论上，单隐藏层的MLP只要神经元数量足够，就能逼近任意连续函数。
3. 适用范围广：可以处理分类、回归等多种任务，对结构化数据的适配性较好。
4. 端到端训练：可以通过反向传播算法直接进行端到端的训练优化。

缺点

1. 参数量大：全连接层的每个神经元都和前一层所有神经元相连，参数量随层数和神经元数快速增长，容易过拟合。
2. 缺乏局部特征提取能力：对图像、序列等数据的局部空间/时序结构不敏感，无法像CNN、RNN那样高效捕捉局部特征。
3. 输入维度限制：需要固定维度的向量输入，对高维结构化数据（如图像）需要先展平，会丢失空间信息。
4. 计算效率较低：全连接的计算矩阵乘法复杂度较高，处理大规模数据时速度较慢。

2、写出 RELU 的表达式，并叙述 RELU 的优点。

$$\text{ReLU}(x) = \max(0, x)$$

3、Softmax 的作用是什么？

1. 将模型的原始输出转换为合法的概率分布，各元素在0-1之间，且和为1，常用于多分类任务中表示不同类别的预测概率。
2. 突出最大值的相对占比。它会放大输入向量中数值较大的元素的权重，让大值对应的概率更接近1，小值对应的概率更接近0，方便模型做出分类决策。
3. 配合交叉熵损失函数。在多分类任务中，Softmax的输出可以和交叉熵损失函数配合使用，让模型训练时的梯度计算更稳定、高效。

4、一个 $n \times n$ 的图像经过 $m \times m$ 的卷积核卷积后的尺寸是多少（步长为1）？

$$\left[\frac{n-m}{s} \right] + 1$$

尺寸 $n \times m$


卷积核： $k \times k$

步长 s

$$\text{输出高: } \left(\frac{n-k}{s} \right) + 1$$

$$\text{宽: } \left(\frac{m-k}{s} \right) + 1$$

$$\text{输出尺寸: } \left[\left(\frac{n-k}{s} \right) + 1 \right] \times \left[\left(\frac{m-k}{s} \right) + 1 \right]$$



上图为 DeepID 模型的网络结构, 请回答:

1、Input layer 到 Convolutional layer1 执行了什么操作?

执行卷积运算

使用 4×4 大小的卷积核遍历原图, 步长为 1, 完成特征提取, 输入单通道图, 输出 20 通道特征图, 尺寸由 39×31 变为 28×28

2、Convolutional layer1 到 Max-pooling1 执行了什么操作?

最大值池化操作

用 2×2 池化窗口, 步长为 2, 在每个窗口内选取最大值保留, 压缩特征图空间尺寸: $28 \times 28 \rightarrow 14 \times 14$, 通道 20.

3、Max-pooling1 到 Convolutional layer2 执行了什么操作?

3、Max-pooling1 $\rightarrow$ Convolutional layer2

执行卷积+激活操作:

- 卷积核尺寸 3×3 , 步长 1, 对 20 通道池化特征图做卷积;

- 叠加偏置后经 ReLU 激活, 输出 40 通道特征图, 尺寸 12×12 ;

- 进一步提取中层人脸局部特征 (五官轮廓、纹理细节)。

4、DeepID 训练的参数

(1) 卷积层参数 (全部 4 层卷积)

- Conv1~Conv3: 卷积核权重、对应偏置 (权重局部共享);

- Conv4: 局部连接层, 无权重共享, 全部神经元权重+偏置都参与训练。

(2) 全连接层参数

- DeepID 隐藏层 (160 维特征层): 与 Conv3、Conv4 跨层连接的全连接权重与偏置;

- Softmax 分类层: 全连接权重、分类偏置。

4、DeepID 模型在训练过程中, 训练了哪些参数?